

Algebra Linear Computacional

SVD e Aproximação de Matrizes

Erickson e Fabricio

*Slides parcialmente baseados em J. Leskovec, A. Rajaraman, J. Ullman:
Mining of Massive Data Sets*



Objetivos de Aprendizagem

1. Entender fundamentos da aplicação do SVD para sistemas de recomendação
2. Calcular representação latente de usuários e filmes
3. Saber fazer a compressão de imagens usando SVD
4. Entender a relação entre qualidade da imagem comprimida e seu espectro (conjunto de valores singulares)
5. Saber encontrar aproximação de matrizes (ou de elementos específicos) usando SVD truncado
6. Conhecer e entender o Teorema de Eckart-Young

Referências Adicionais

- YouTube
 - Jure Leskovec: SVD for Recommender Systems
<https://youtu.be/K38wVcdNuFc>
 - Steve Brunton: SVD for Image Compression (Python)
<https://youtu.be/H7qMMudo3e8>

$$AV=U\Sigma$$

$$\begin{matrix} m \times m \\ A \end{matrix} \begin{bmatrix} v_1 & v_2 & \dots & v_r \end{bmatrix} = \begin{bmatrix} u_1 & u_2 & \dots & u_r \end{bmatrix} \begin{bmatrix} \sigma_1 & & & \\ & \ddots & & \\ & & \sigma_r & \end{bmatrix}$$

V
 $n \times r$

U
 $m \times r$

Σ
 $r \times r$

$Av_i = \sigma_i u_i$

Nota: Estas dimensões correspondem ao SVD reduzido.

Retificando a explicação: precisamos transformar U e V em matrizes **quadradas**.



Tornando V quadrada

Se o espaço coluna $C(A)$ tem dimensão r , existem r vetores $\sigma_i u_i$ independentes que podem ser escritos como Av_i .

Sabemos ainda que o espaço nulo $N(A)$ tem dimensão $n-r$.

Logo, existem $n-r$ vetores v_j independentes tais que $Av_j = 0$. Esses vetores são ortogonais a v_1, \dots, v_r . Concatenando-os

a V ,

$$A \begin{bmatrix} | & \dots & | & | & \dots & | \\ v_1 & \dots & v_r & \underline{v_{r+1}} & \dots & v_n \\ | & \dots & | & | & \dots & | \end{bmatrix} = \underbrace{\begin{bmatrix} | & \dots & | \\ u_1 & \dots & u_r \\ | & \dots & | \end{bmatrix}}_{m \times r} \underbrace{\begin{bmatrix} \sigma_1 & \dots & 0 & 0 & \dots & 0 \\ \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ 0 & \dots & \sigma_r & 0 & \dots & 0 \end{bmatrix}}_{r \times n}$$

$m \times r$ $m-r$



Tornando U quadrada

Como os vetores u_i estão no \mathbb{R}^m , existem $m-r$ vetores independentes u_j ortogonais a u_1, \dots, u_r . Logo, podemos concatená-los a U , desde que sejam adicionadas $m-r$ linhas nulas em Σ :

$$\underbrace{A \begin{bmatrix} | & \dots & | & | & \dots & | \\ v_1 & \dots & v_r & v_{r+1} & \dots & v_n \\ | & \dots & | & | & \dots & | \end{bmatrix}}_{n \times n} = \underbrace{\begin{bmatrix} | & \dots & | & | & \dots & | \\ u_1 & \dots & u_r & u_{r+1} & \dots & u_m \\ | & \dots & | & | & \dots & | \end{bmatrix}}_{m \times m} \underbrace{\begin{bmatrix} \sigma_1 & \dots & 0 & 0 & \dots & 0 \\ \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ 0 & \dots & \sigma_r & 0 & \dots & 0 \\ 0 & \dots & 0 & 0 & \dots & 0 \\ \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ 0 & \dots & 0 & 0 & \dots & 0 \end{bmatrix}}_{m \times n}$$

Handwritten annotations: A red bracket above the first $m \times r$ columns of the U matrix is labeled $m \times r$. A red bracket above the next $m-r$ columns is labeled $m-r$. A red bracket to the left of the last $m-r$ rows of the Σ matrix is labeled $m-r$.

Nota: Estas dimensões correspondem ao SVD completo.



Do SVD completo ao reduzido

SVD Completo

$$\underbrace{A}_{m \times n} = \underbrace{U}_{m \times m} \underbrace{\Sigma}_{m \times n} \underbrace{V^T}_{n \times n}$$

$$\begin{aligned} A V &= U \Sigma \\ m \times n \quad m \times n \quad m \times n \quad m \times n \\ A &= U \Sigma V^T \\ m \times n \quad m \times r \quad r \times r \quad r \times n \end{aligned}$$

Como apenas os r primeiros elementos da diagonal de Σ são não-nulos, podemos tomar esta submatriz, descartando as colunas $r+1, \dots, m$ de U e as linhas $r+1, \dots, n$ de V^T . O resultado, denotado pelas mesmas letras, é

SVD Reduzido

$$\underbrace{A}_{m \times n} = \underbrace{U}_{m \times r} \underbrace{\Sigma}_{r \times r} \underbrace{V^T}_{r \times n}$$



Exemplo de uma matriz tall-thin

	Matrix	Alien	Serenity	Casablanca	Amelie	
↑	1	1	1	0	0	Ana
SciFi	3	3	3	0	0	Bruno
↓	4	4	4	0	0	...
	5	5	5	0	0	
↑	0	0	0	4	4	
Romance	0	0	0	5	5	
↓	0	0	0	2	2	



Aprendendo sobre espaço latente

$$\begin{array}{c}
 \uparrow \\
 \text{SciFi} \\
 \downarrow \\
 \uparrow \\
 \text{Romance} \\
 \downarrow
 \end{array}
 \begin{array}{c}
 \text{Matrix} \\
 \text{Alien} \\
 \text{Serenity} \\
 \text{Casablanca} \\
 \text{Amelie}
 \end{array}
 \begin{bmatrix}
 1 & 1 & 1 & 0 & 0 \\
 3 & 3 & 3 & 0 & 0 \\
 4 & 4 & 4 & 0 & 0 \\
 5 & 5 & 5 & 0 & 0 \\
 0 & 0 & 0 & 4 & 4 \\
 0 & 0 & 0 & 5 & 5 \\
 0 & 0 & 0 & 2 & 2
 \end{bmatrix}
 =
 \begin{bmatrix}
 0.14 & 0.00 \\
 0.42 & 0.00 \\
 0.56 & 0.00 \\
 0.70 & 0.00 \\
 0.00 & 0.60 \\
 0.00 & 0.75 \\
 0.00 & 0.30
 \end{bmatrix}
 \times
 \begin{bmatrix}
 12.4 & 0 \\
 0 & 9.5
 \end{bmatrix}
 \times
 \begin{bmatrix}
 0.58 & 0.58 & 0.58 & 0.00 & 0.00 \\
 0.00 & 0.00 & 0.00 & 0.71 & 0.71
 \end{bmatrix}$$



Usuário e conceito

SciFi-concept Romance-concept

↑ SciFi
↓
↑ Romance
↓

	Matrix	Alien	Serenity	Casablanca	Amelie
SciFi	1	1	1	0	0
	3	3	3	0	0
	4	4	4	0	0
	5	5	5	0	0
Romance	0	0	0	4	4
	0	0	0	5	5
	0	0	0	2	2

=

0.14	0.00
0.42	0.00
0.56	0.00
0.70	0.00
0.00	0.60
0.00	0.75
0.00	0.30

\times

12.4	0
0	9.5

\times

0.58	0.58	0.58	0.00	0.00
0.00	0.00	0.00	0.71	0.71

U is "user-to-concept" similarity matrix



Filme e conceito

$$\begin{matrix}
 \uparrow \text{SciFi} \\
 \downarrow \\
 \uparrow \text{Romance} \\
 \downarrow
 \end{matrix}
 \begin{matrix}
 \text{Matrix} \\
 \text{Alien} \\
 \text{Serenity} \\
 \text{Casablanca} \\
 \text{Amelie}
 \end{matrix}
 \begin{bmatrix}
 1 & 1 & 1 & 0 & 0 \\
 3 & 3 & 3 & 0 & 0 \\
 4 & 4 & 4 & 0 & 0 \\
 5 & 5 & 5 & 0 & 0 \\
 0 & 0 & 0 & 4 & 4 \\
 0 & 0 & 0 & 5 & 5 \\
 0 & 0 & 0 & 2 & 2
 \end{bmatrix}
 =
 \begin{matrix}
 \text{SciFi-concept} & \text{Romance-concept} \\
 \downarrow & \swarrow
 \end{matrix}
 \begin{bmatrix}
 0.14 & 0.00 \\
 0.42 & 0.00 \\
 0.56 & 0.00 \\
 0.70 & 0.00 \\
 0.00 & 0.60 \\
 0.00 & 0.75 \\
 0.00 & 0.30
 \end{bmatrix}
 \times
 \begin{bmatrix}
 12.4 & 0 \\
 0 & 9.5
 \end{bmatrix}
 \times
 \begin{bmatrix}
 0.58 & 0.58 & 0.58 & 0.00 & 0.00 \\
 0.00 & 0.00 & 0.00 & 0.71 & 0.71
 \end{bmatrix}$$

V is "movie to concept" similarity matrix



Peso de um conceito

$$A = \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T$$

$$= \sigma_1 \begin{bmatrix} \end{bmatrix} + \sigma_2 \begin{bmatrix} \end{bmatrix}$$

SciFi-concept
 Romance-concept

Σ is the "concept strength" matrix

Matrix Alien Serenity Casablanca Amelie
 SciFi
 Romance

$$\begin{bmatrix} 1 & 1 & 1 & 0 & 0 \\ 3 & 3 & 3 & 0 & 0 \\ 4 & 4 & 4 & 0 & 0 \\ 5 & 5 & 5 & 0 & 0 \\ 0 & 0 & 0 & 4 & 4 \\ 0 & 0 & 0 & 5 & 5 \\ 0 & 0 & 0 & 2 & 2 \end{bmatrix} = \begin{bmatrix} 0.14 & 0.00 \\ 0.42 & 0.00 \\ 0.56 & 0.00 \\ 0.70 & 0.00 \\ 0.00 & 0.60 \\ 0.00 & 0.75 \\ 0.00 & 0.30 \end{bmatrix} \times \begin{bmatrix} 12.4 & 0 \\ 0 & 9.5 \end{bmatrix} \times \begin{bmatrix} 0.58 & 0.58 & 0.58 & 0.00 & 0.00 \\ 0.00 & 0.00 & 0.00 & 0.71 & 0.71 \end{bmatrix}$$



Exemplo um pouco mais real

Note que existem usuários que vão assistir filmes de vários tipos (isso pode ser apenas ruído)

The diagram illustrates a matrix multiplication process for movie ratings. It shows a 6x5 matrix of user ratings for movies, a 5x3 matrix of genre ratings for movies, and a 3x5 matrix of genre ratings for users. The resulting 6x5 matrix shows predicted ratings.

User-Movie Matrix (6x5):

	Matrix	Alien	Serenity	Casablanca	Amelie
1	1	1	1	0	0
3	3	3	3	0	0
4	4	4	4	0	0
5	5	5	5	0	0
0	2	0	4	4	
0	0	0	5	5	
0	1	0	2	2	

Genre-Movie Matrix (5x3):

	Matrix	Alien	Serenity	Casablanca	Amelie
0.13	-0.02	-0.01			
0.41	-0.07	-0.03			
0.55	-0.09	-0.04			
0.68	-0.11	-0.05			
0.15	0.59	0.65			
0.07	0.73	-0.67			
0.07	0.29	0.32			

Genre-User Matrix (3x5):

	Matrix	Alien	Serenity	Casablanca	Amelie
12.4	0	0			
0	9.5	0			
0	0	1.3			

Resulting Matrix (6x5):

	Matrix	Alien	Serenity	Casablanca	Amelie
0.56	0.59	0.56	0.09	0.09	
-0.12	0.02	-0.12	0.69	0.69	
0.40	-0.80	0.40	0.09	0.09	



Exemplo um pouco mais real

$$\begin{bmatrix} 1 & 1 & 1 & 0 & 0 \\ 3 & 3 & 3 & 0 & 0 \\ 4 & 4 & 4 & 0 & 0 \\ 5 & 5 & 5 & 0 & 0 \\ 0 & 2 & 0 & 4 & 4 \\ 0 & 0 & 0 & 5 & 5 \\ 0 & 1 & 0 & 2 & 2 \end{bmatrix} \approx \begin{bmatrix} 0.13 & -0.02 & -0.01 \\ 0.41 & -0.07 & -0.03 \\ 0.55 & -0.09 & -0.04 \\ 0.68 & -0.11 & -0.05 \\ 0.15 & 0.59 & 0.65 \\ 0.07 & 0.73 & -0.67 \\ 0.07 & 0.29 & 0.32 \end{bmatrix} \times \begin{bmatrix} 12.4 & 0 & 0 \\ 0 & 9.5 & 0 \\ 0 & 0 & 1.3 \end{bmatrix} \times \begin{bmatrix} 0.56 & 0.59 & 0.56 & 0.09 & 0.09 \\ -0.12 & 0.02 & -0.12 & 0.69 & 0.69 \\ 0.40 & -0.80 & 0.40 & 0.09 & 0.09 \end{bmatrix}$$



Um sistema de recomendação simples

- Temos k perfis de usuários
 - Cada usuário será o resultado da combinação linear desses perfis (comédia, drama, ação)
 - A matrix “verdadeira” então terá posto k !
- Pergunta
 - Como recomendar um filme para um determinado usuário?



Um sistema de recomendação simples

$$\begin{bmatrix} 1 & 1 & 1 & 0 & 0 \\ \underline{0} & 3 & 3 & 0 & 0 \\ 4 & 4 & \underline{0} & 0 & 0 \\ 5 & 5 & 5 & 0 & 0 \\ 0 & 2 & 0 & 4 & 4 \\ 0 & 0 & 0 & 5 & 5 \\ 0 & 1 & 0 & 2 & 2 \end{bmatrix} = \overset{U}{\begin{bmatrix} 0.14 & -0.06 & -0.04 \\ 0.30 & -0.11 & -0.61 \\ 0.43 & -0.16 & 0.76 \\ 0.74 & -0.31 & -0.18 \\ 0.15 & 0.53 & 0.02 \\ 0.07 & 0.70 & -0.03 \\ 0.07 & 0.27 & 0.01 \end{bmatrix}} \times \overset{\Sigma}{\begin{bmatrix} 12.4 & 0 & 0 \\ 0 & 9.5 & 0 \\ 0 & 0 & 1.3 \end{bmatrix}} \times \begin{bmatrix} 0.51 & 0.66 & 0.44 & 0.23 & 0.23 \\ -0.24 & -0.13 & -0.21 & 0.66 & 0.66 \\ 0.59 & 0.08 & -0.80 & 0.01 & 0.01 \end{bmatrix} \overset{V^T}{\underbrace{\hspace{10em}}}$$



Um sistema de recomendação simples

Como estamos supondo termos $k=2$ perfis

$$\begin{bmatrix} 1 & 1 & 1 & 0 & 0 \\ 0 & 3 & 3 & 0 & 0 \\ 4 & 4 & 0 & 0 & 0 \\ 5 & 5 & 5 & 0 & 0 \\ 0 & 2 & 0 & 4 & 4 \\ 0 & 0 & 0 & 5 & 5 \\ 0 & 1 & 0 & 2 & 2 \end{bmatrix} \approx \begin{bmatrix} 0.14 & -0.06 & -0.04 \\ 0.30 & -0.11 & -0.61 \\ 0.43 & -0.16 & 0.76 \\ 0.74 & -0.31 & -0.18 \\ 0.15 & 0.53 & 0.02 \\ 0.07 & 0.70 & -0.03 \\ 0.07 & 0.27 & -0.01 \end{bmatrix} \times \begin{bmatrix} 12.4 & 0 & 0 \\ 0 & 9.5 & 0 \\ 0 & 0 & -1.3 \end{bmatrix} \times \begin{bmatrix} 0.51 & 0.66 & 0.44 & 0.23 & 0.23 \\ -0.24 & -0.13 & -0.21 & 0.66 & 0.66 \\ 0.59 & 0.08 & -0.80 & 0.01 & 0.01 \end{bmatrix}$$



Um sistema de recomendação simples

Ao realizar a multiplicação (após remover o menor valor singular)


0.96	1.14	0.82	-0.01	-0.01
1.94	2.32	1.66	0.07	0.07
2.77	3.32	2.37	0.08	0.08
4.84	5.74	4.14	-0.08	0.08
0.40	1.42	0.33	4.06	4.06
-0.42	0.63	-0.38	4.92	4.92
0.20	0.71	0.16	2.03	2.03

1	1	1	0	0
2	2	2	0	0
3	3	3	0	0
4	4	4	0	0
⋮				



Compressão de Imagens

~80% da internet é imagem!



Compressão de Imagens

Dimensão: 3024 x 4032

Número de bytes: 12.192.768 x 3 (considerando cor)



Compressão de Imagens

Podemos tentar aproximar a matriz A que representa a imagem por A_k

$$A_k = \sigma_1 u_1 v_1^T + \dots + \sigma_k u_k v_k^T$$

$$A = \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T + \dots + \underline{\sigma_r u_r v_r^T}$$

$$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_k \geq \sigma_{k+1} \geq \dots \geq \sigma_r$$



Compressão de Imagens

$(3024, 1)$
 $U, \text{sigma}, Vt = \text{np.linalg.svd}(\text{img_gray})$
elementos da diagonal de Σ *3024×4032*

- $U.\text{shape}$: 3024×3024
- $Vt.\text{shape}$: 4032×4032
- $\text{sigma}.\text{shape}$: 3024×3024 (sendo apenas 3024 valores diferentes de zero)

*$\text{sigma} = \text{np.diag}(\text{sigma})$
 3024×3024*

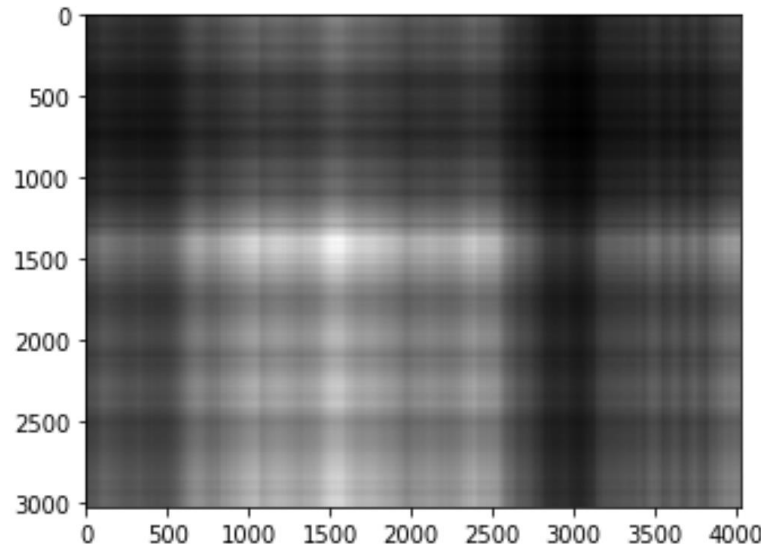
$$A = U \Sigma V^T$$

$m \times n$ $m \times m$ $n \times n$ $m \times n$



Compressão de Imagens

A primeira aproximação seria: $A_1 = \sigma_1 u_1 v_1^T$



$\sigma_1[0] * U[:,0].\text{reshape}((-1,1)) @ Vt[0,:].\text{reshape}((1,-1))$
`reconstimg = np.matrix(U[:, :1]) * np.diag(sigma[:1]) * np.matrix(V[:1, :])`




Compressão de Imagens

Ficou bom?

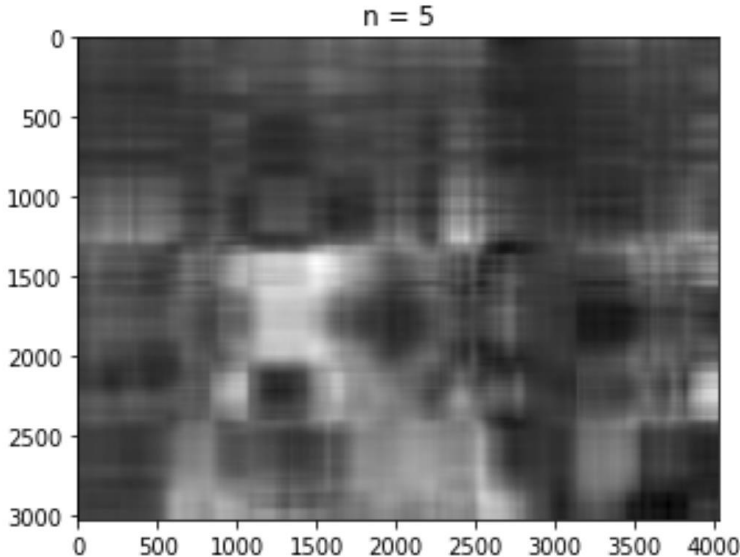
$$\underbrace{RMSE}_{M \times N} = \sqrt{\frac{1}{\underbrace{MN}_{m=0 \ n=0}} \sum_{m=0}^{M-1} \sum_{n=0}^{N-1} (\underbrace{I1(m,n)}_{\text{original}} - \underbrace{I2(m,n)}_{\text{aproximada}})^2}.$$

MSE: 2486.98



Compressão de Imagens



Uma aproximação seria usar mais valores singulares: A_5



```
reconstimg = np.matrix(U[:, :5]) @ np.diag(sigma[:5]) @ np.matrix(V[:5, :])
```




Até quando precisamos ir?



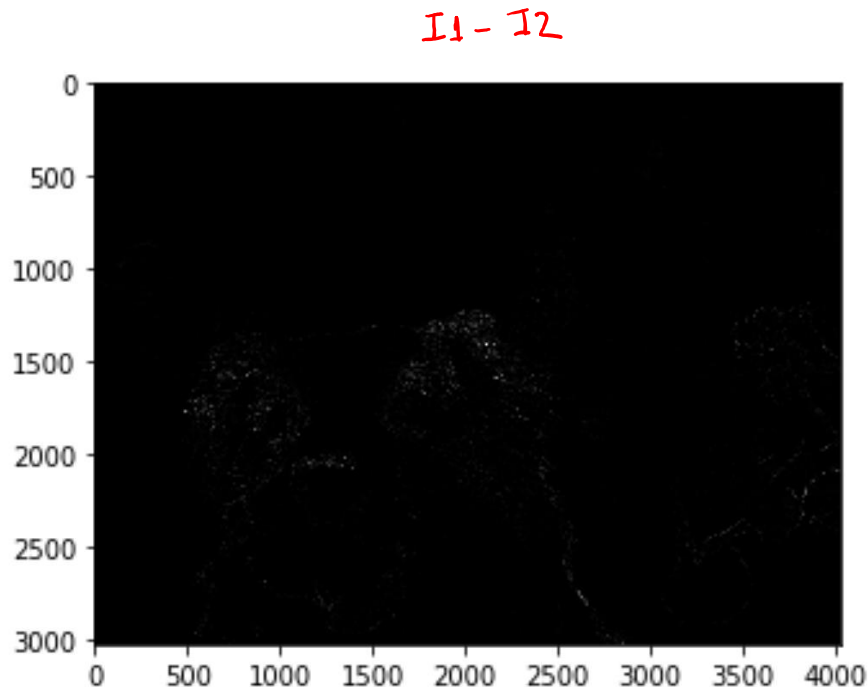
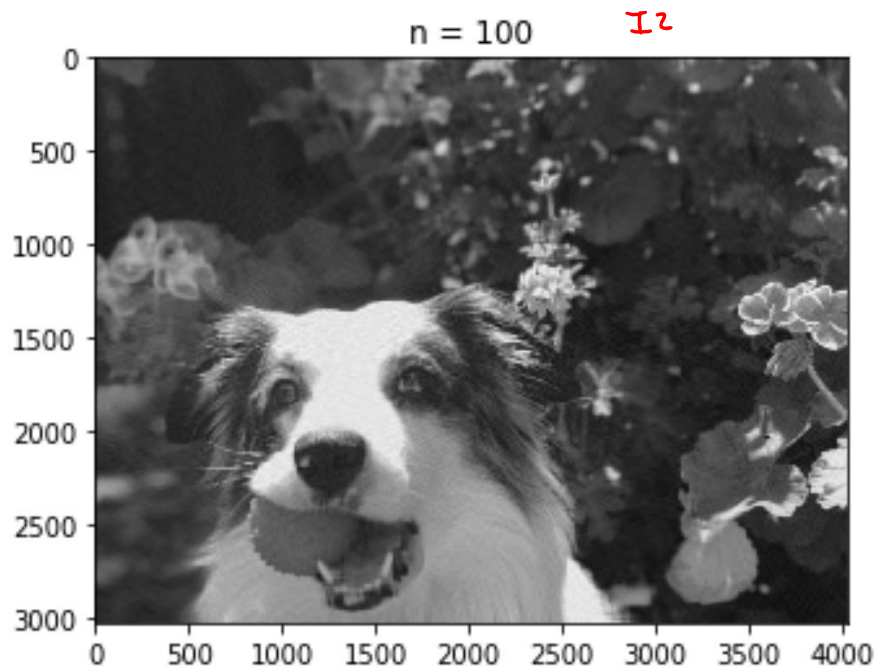
Até quando precisamos ir?

Regra do dedo: cortar de maneira a manter entre 80-90% da “energia”

$$t = \frac{\sum_{i=1}^k \sigma_i^2}{\sum_{i=1}^n \sigma_i^2} \approx 80\%$$



$n=100$ já temos uma ótima aproximação



O quanto estamos usando de espaço?

$$Tx = (100 \cdot 3024 + 100 + 100 \cdot 4032) / (3024 \cdot 4032)$$

$$Tx = 5.7\%$$

100 colunas de U 3024×3024
100 elementos de Σ 3024
100 linhas de V^T 4032×4032

Razão de compressão:

$$(3024 \cdot 4032) / (100 \cdot 3024 + 100 + 100 \cdot 4032) = 17 \text{ vezes!}$$



Aproximação da matriz A

É possível encontrar uma matriz B com posto k que seja mais próxima de A e que não seja A_k ?



Aproximação de matriz

Eckart-Young: Suponha B uma matriz de posto k .
Então B será uma aproximação no máximo tão
boa quanto A_k

$$\|A - A_k\|_2 \leq \|A - B\|_2$$

onde B tem posto k .

$$A_k = \sigma_1 u_1 v_1^T + \cdots + \sigma_k u_k v_k^T$$



Aproximação de matriz

Se B tem posto k , então

$\|C\|_2$ é o maior valor singular.

$$\|A - B\|_2 \geq \|A - A_k\|_2 = \sigma_{k+1}$$

$$\underline{\sigma_{k+1} u_{k+1} v_{k+1}^T + \dots + \sigma_p u_p v_p^T}$$

Norma de Frobenius:

$$\|A\|_F = \sqrt{|a_{11}|^2 + |a_{12}|^2 + \dots + |a_{mn}|^2}$$

$$\|A\|_F \geq \|A\|_2$$

